# Как устроен запрос: 12 шагов в одном WITH

**1 metric_dict**
Роль, направление, допуск

**2 filtered**
Фильтры по продукту и бакету

**3 step1_rows**
x и y каждой метрики по строкам

**4 step2_kappa**
κ = метрика в контроле

**5 step3_lin**
L = x − κ·y

**6 step4_grp**
n, среднее и дисперсия L

**7 step5_t**
Каждый пилот против контроля

**8 step6_aux**
t-статистика, число пилотов

**9 step7_pw**
Хвост распределения для мощности

**10 step8_res**
CI, lift, p-value, MDE

**11 step9_flags**
Поправка, статус гардрейла

**12 SELECT**
Итог и сводка по пилоту

Фильтры применяются до расчёта κ и L, поэтому каждый срез считается честно, а не по всем данным.

ЛИНЕАРИЗАЦИЯ · 1 ИЗ 3

# Как отношение сумм превращается в среднее

1 · ЗАДАЧА

## Отличить эффект от шума

Для среднего шум считается формулой √(дисперсия / n). Но наша метрика ΣX / ΣY — не среднее, а отношение сумм.

2 · ПРИЁМ

## Сравнить строку с нормой контроля

$$L = x - к \cdot y$$

Факт минус ожидание при уровне контроля к. Пример: 3 − 0,12 · 20 = +0,6.

3 · ПОЧЕМУ РАБОТАЕТ

$$метрика - к = (\Sigma X - к \cdot \Sigma Y) / \Sigma Y$$
$$= среднее\ L / среднее\ y$$

Точное равенство. В контроле среднее L = 0, в пилоте оно пропорционально эффекту.

4 · ИТОГ

## Сравнить метрики = сравнить средние L

Дальше обычный t-тест. Эффект в единицах метрики = разница средних L / среднее y.

# Откуда берётся формула шума

| | |
|---|---|
| $Var(L) = \sigma^2$ | Разброс одного L. В запросе — VARIANCE(l) |
| $Var(\Sigma L) = n \cdot \sigma^2$ | У независимых величин разбросы складываются |
| $Var(\Sigma L \,/\, n) = \sigma^2 \,/\, n$ | Деление на n уменьшает разброс в $n^2$ раз |
| $se^2 = \sigma^2_t \,/\, n_t + \sigma^2_c \,/\, n_c$ | Пилот и контроль независимы — их разбросы тоже складываются |
| $t = \text{разница} \,/\, se \approx N(0, 1)$ | Среднее многих независимых чисел — «колокол» (ЦПТ). Без эффекта $\lvert t \rvert > 1{,}96$ в 5% случаев |

# Итог: отношение превратилось в среднее

### Что сохраняется

- Значение метрики ΣX / ΣY
- Веса строк
- Знак и размер эффекта

### Что важно помнить

- к берём из контроля, общий для всех групп
- Нужны тысячи наблюдений
- Строки считаются независимыми

Дальше — обычный t-тест на L: шум, t, p-value, интервал.

# t-тест на L: шум, t, p-value, интервал

| | |
|---|---|
| $se = \sqrt{var_t / n_t + var_c / n_c}$ | Шум разницы. Шум среднего падает с ростом n, шумы двух групп складываются (формула Уэлча) |
| $t = diff_L / se$ | Во сколько раз эффект больше шума. Знак — направление эффекта |
| $p = 2 \cdot (1 - \Phi(\lvert t \rvert))$ | Площадь двух хвостов колокола. В SQLite — приближение Abramowitz–Stegun, ошибка < $10^{-7}$ |
| $CI = diff_L \pm 1{,}96 \cdot se$ | 95% интервал. $\lvert t \rvert > 1{,}96 \Leftrightarrow p < 0{,}05$ — флаг значимости |

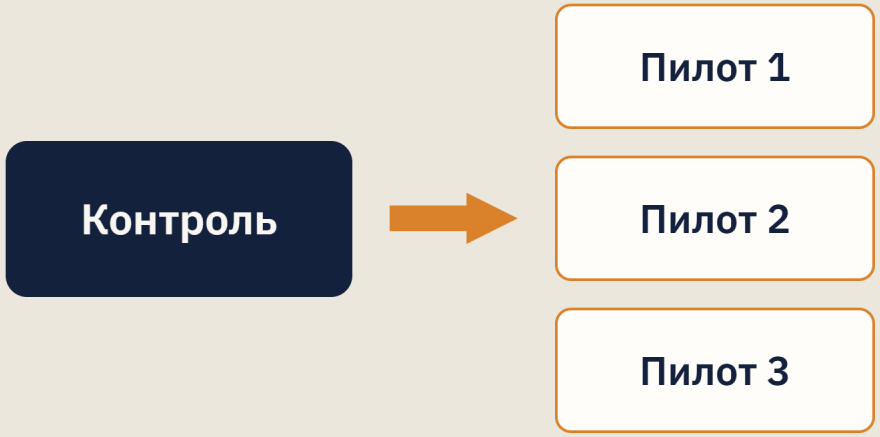
# Перевод обратно в единицы метрики

```
diff_L = mean_y пилота × (метрика пилота - метрика контроля)
```

| Показатель | Формула | Единицы |
|---|---|---|
| Абсолютный эффект | diff_L / mean_y_t | п.п., рубли |
| Lift | diff_L / (mean_y_t · к) | % к контролю |
| Границы CI | (diff_L ± 1,96 · se) / тот же делитель | как у эффекта |

t и p-value от перевода не зависят: числитель и знаменатель делятся на одно и то же число.

# Несколько пилотов: каждый против контроля




**step5_t**: self-join статистик — контроль в паре с каждой другой группой. Одна строка = метрика × пилот.

**Поправка Бонферрони**: порог α = 0,05 / число пилотов. При трёх пилотах — 0,0167.

Без поправки шанс, что хоть один из трёх пилотов покрасится случайно, ≈ 14%.

Решение принимаем по **is_significant_adj** и **effect_verdict**: «лучше», «хуже», «нет различий».

# Guardrail-метрики: не ухудшили ли мы

Эффект умножается на direction, чтобы плюс всегда значил «лучше». Дальше смотрим на худшую границу интервала и допуск margin.

| Статус | Условие | Смысл |
|---|---|---|
| нарушен | верхняя граница < 0 | Ухудшение значимо |
| ок | нижняя граница > −margin | Худший исход в пределах допуска |
| недостаточно данных | иначе | Интервал слишком широкий |

margin — бизнес-решение. Сводка по пилоту: pilot_guardrails_violated и pilot_guardrails_unclear.

# Как читать результат

### Решение

effect_verdict по primary-метрике, с поправкой на число пилотов

### Блокер

pilot_guardrails_violated > 0 — пилот ухудшил гардрейл

### «Нет различий» ≠ «нет эффекта»

Сравните ожидаемый эффект с mde_rel: мог ли тест его увидеть

### Ограничения

Строки считаются независимыми; хвосты денежных метрик; не перебирать срезы в поисках прокраса